

Проект по Machine Learning

Предсказание покупки в интернет-магазине

eCommerce behavior data · Kaggle · Oct 2019 – Apr 2020

Команда:

Насиров Анар Чингиз оглы

Журбинский Роман Игоревич

Куготов Беслан Тимурович

Домнина Анастасия Андреевна

285M

пользователей

7

месяцев данных

4

типа событий

Датасет и постановка задачи

О датасете

Источник: Kaggle · mkechinov

Период: Окт 2019 — Апр 2020

Объём: 285 млн пользователей

Сэмпл: 300 000 случайных пользователей (~5%)

Гранулярность: событие пользователя (строка)

Ключевые признаки

- event_time · user_id · user_session
- product_id · category_code
- brand · price · event_type

🎯 Задача

Бинарная классификация:
совершит ли пользователь покупку
товара (user_id + product_id)?

Метрика

ROC-AUC


Дисбаланс классов
требует AUC, а не Accuracy

Типы событий

- view 71.7%
- cart 15.8%
- purchase 8.0%
- remove_cart 4.5%

EDA: Активность пользователей


Активность по часам суток



Пик активности: 18–20 ч (вечер)


Провал: 3–5 ч ночи

Воронка конверсии (сред. по дням)



EDA: Цена и поведение пользователей

Распределение цен (покупки)



Длинный правый хвост: большинство покупок — недорогие товары до \$100

Гипотезы, подтверждённые EDA



Добавившие в корзину покупают чаще



Дешёвые товары покупают чаще



Категории имеют разную конверсию




Повторные пользователи покупают активнее

Целевая переменная: покупка товара пользователем → target = 1 (~8% случаев)

Этап 1: Baseline модели

Фичи (агрегация по user_id + product_id): price_mean · price_max · cnt_events · cnt_view → target = max(is_purchase)

ROC-AUC по моделям



Выводы

→ DummyClassifier — случайный baseline (0.50)

→ Логрег улавливает линейные зависимости (0.74)

→ Decision Tree даёт нелинейности (0.82)

★ Random Forest — лучший baseline (0.89)

Этап 2: Поиск аномалий

Два уровня анализа аномалий

1. Уровень сырых событий

Признак: price

Длинный правый хвост

e-commerce: норма vs ошибка

2. Уровень user+product

Агрегированная таблица

Необычные комбинации признаков

Взаимодействие переменных

Методы

Z-score

Строгий, нормальное распределение. Лучше с $\log_{1p}(\text{price})$

IQR

Находит больше выбросов. Устойчив к хвостам

Тест Граббса

Самые экстремальные точки. Не подходит для массового фильтра

Isolation Forest

Необычные комбинации признаков. contamination=3%

LOF

Низкая локальная плотность. n_neighbors=35

Этап 2: Влияние anomaly-признаков на модель

Сравнение моделей: без аномалий vs с аномалиями

Модель	N признаков	ROC-AUC	PR-AUC
RF без anomaly-признаков	4	0.8920	0.4210
RF с anomaly-признаками	4 + 8	0.9010	0.4380

Сравнение методов детекции

Statistical flags

Доля аномалий: ~5.2%

target (аномалии): 7.8%



Isolation Forest

Доля аномалий: ~3.0%

target (аномалии): 6.1%



LOF

Доля аномалий: ~3.0%


target (аномалии): 5.9%



Решение: аномалии НЕ удаляем — превращаем в признаки (флаги, счётчики, IF-score)

Этап 3: Интерпретация — SHAP + LIME

Важность признаков: SHAP vs RF importance



Beeswarm plot (LR): cnt_events и cnt_view имеют широкий разброс SHAP-значений — наибольший вклад в неопределённость предсказаний модели

Что показывает SHAP

● cnt_events — ключевой предиктор: больше действий = выше вероятность покупки

● Высокая цена снижает вероятность покупки (отриц. SHAP-вклад)

■ SHAP и RF importance показывают одинаковый порядок признаков

LIME — локальная интерпретация

Объясняет отдельное предсказание:
линейная аппроксимация RF вокруг точки

Этап 3: SHAP-эмбеддинги и кластеризация



Результаты: ROC-AUC по конфигурациям

Только SHAP-признаки	0.9130
RF после очистки SHAP-аномалий	~0.89
SHAP + исходные признаки	0.9210
RF с кластерами (SHAP → PCA → KMeans)	~1.00 ⚠️
⚠️ ROC-AUC ≈ 1.0 при кластеризации — признак переобучения или утечки таргета через SHAP-значения	

Итоги проекта

1 EDA

view→cart: 4.2%, cart→purchase: 41%

Пик активности: 18–20 ч

Правохвостое распределение цен

2 Baseline

4 модели: Dummy → RF

Лучший baseline: RF ROC-AUC = 0.89

Метрика: ROC-AUC (дисбаланс классов)

3 Аномалии + SHAP

5 методов детекции аномалий

Anomaly-признаки: +0.009 ROC-AUC

SHAP embeddings → кластеры (осторожно: overfitting)

Прогресс ROC-AUC: Dummy 0.50 → LogReg 0.74 → DecTree 0.82 → RF 0.89 → RF + SHAP 0.921